Введение в OpenCL

Николай Пономарев

Математико-механический факультет СПбГУ

10 апреля 2025 г.

OpenCL

- OpenCL (Open Computing Language) for **Parallel** Programming of **Heterogeneous** Systems
- Один из стандартов The Khronos Group — консорциума, который занимается разработкой открытых стандартов в областях параллельных вычислений, машинного обучения, компьютерной графики
  - Насчитывает более 180 организаций-участников
  - Поддерживает 21 стандарт, среди них Vulkan, OpenGL, OpenCL, SPIR-V, WebGL
- Можно найти в девайсах от AMD, Arm, Google, Imagination Technologies, Intel, NVIDIA, Qualcomm, ...
- Используется в OpenCV, FFmpeg, ViennaCL, GNU Octave, Matlab, ...

Параллелизм по данным

- Можем применить функцию к различным элементам коллекции независимо[1]

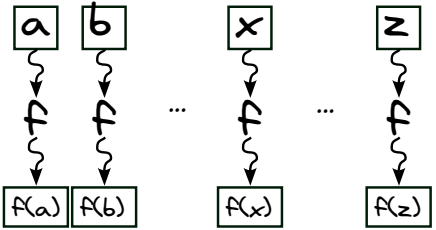

- Single Instruction Multiple Data (SIMD) — реализация параллелизма по данным на уровне процессора
  - Инструкция ⇒ действия более простые и гранулярные
  - Данные должны быть однородны
- Хорошо подходит для решения задач линейной алгебры и обработки изображений

[1] Картинка из https://github.com/YaccConstructor/articles/tree/master/2025/GPGPU_OpenCL_Intro

Устройства, где работает OpenCL

- Central Processing Unit, CPU
- Graphics Processing Unit, GPU
- Digital Signal Processor, DSP
- Field-Programmable Gate Array, FPGA
- Tensor Processor
- ...

Версии OpenCL

1.0 Первый релиз, 2008 г.

1.2 Baseline для современного оборудования, 2011 г.

2.x Крупное обновление, но откатили в 3.0, 2013–2017 г.

3.0 База из 1.2 и расширения по усмотрению производителя, 2020 г.

Khronos часто показывает в примерах код для 2.x — но устройства почти не поддерживают эти версии!

Обычно в пользовательских устройствах можно найти либо 1.2, либо 3.0

Структура программы

- Программа исполняется на двух устройствах: хосте и ускорителе
- Хост (host) — обычно CPU устройства
  - Отвечает за общение с внешним миром, подготовку данных и запуск кода на девайсе
  - Можно использовать привычный язык программирования
- Ускоритель (девайс, device) — вычислительные модули, поддерживающие OpenCL
  - Исполняет код по просьбе хоста
  - Язык программирования «прибит»
  - Программу обычно называют «ядром» (kernel)

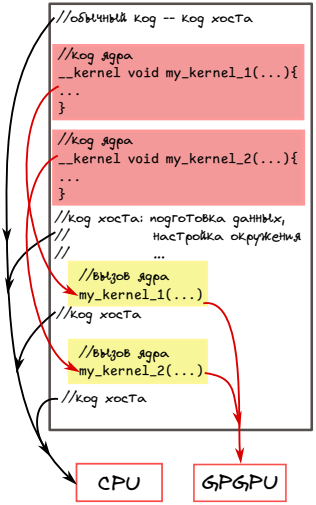

Взаимодействие хоста и ускорителя

- Обнаружение, подключение и конфигурация устройств
- Работа с памятью
  - Выделение/освобождение
  - Контроль доступа и синхронизация между хостом и ускорителем
  - Основной примитив — буфер, но с 2.0 поддерживается и Shared Virtual Memory (SVM)
- Выполнение команд
  - Передача данных, запуск ядер, синхронизация
  - Основной интерфейс взаимодействия — очередь команд
    - Неблокирующая: центральный процессор ставит задачи, но не дожидается их исполнения
    - Нужны дополнительные действия чтобы узнать, когда закончилась определённая задача
    - In-order: команды выполняются строго друг за другом
    - Может быть out-of-order
    - Синхронизация между несколькими очередями возможна, но требует отдельной работы

Языки программирования

Языки программирования хоста:

- **C**
- **C++**
- Python[2]
- Rust[3]
- Julia[4]
- ...

Языки программирования ускорителя:

- **The OpenCL C Kernel Language**
- C++ for OpenCL

[2] PyOpenCL: `https://documen.tician.de/pyopencl/`
[3] ocl: `https://github.com/cogciprocate/ocl`
[4] OpenCL.jl: `https://github.com/JuliaGPU/OpenCL.jl`

The OpenCL C Kernel Language

- Диалект C99: специальные типы данных (векторы, изображения, очереди команд), модификаторы памяти (глобальная, локальная, константная, приватная)
- Online компиляция, но можно и offline
- Собственный stdlib
- Расширения
  - Предусмотренные стандартом: `cl_khr_fp64`, `cl_khr_int64_extended_atomics`, ...
  - Расширения от вендоров: `cl_nv_pragma_unroll`, `cl_amd_fp64`, ...

Пример 1

См. директорию `cpp_vadd_example`

Параллельность

- Виртуальная решётка (**NDRange**) «потоков» (**work-items**)
  - одно-, двух-, трёхмерная
  - Группировка узлов в рабочие группы (**work-group**) фиксированного размера
  - Возможность получить глобальные и локальные координаты «потока»
- Параметры (размеры) решётки связаны с «размерами» обрабатываемых данных

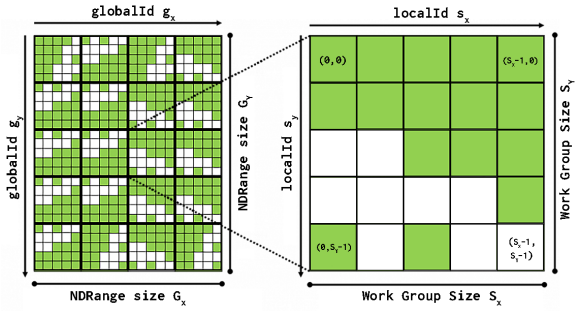

Модель памяти

Память в OpenCL выстраивается в иерархию:

- Память хоста — не доступна потокам напрямую
- Глобальная/константная память — доступна в любой части ускорителя
- Локальная — доступна группе «потоку»
- Приватная — доступна только «потоку»

Управление памятью ручное. Перемещение и синхронизация осуществляются явно, по команде программиста.

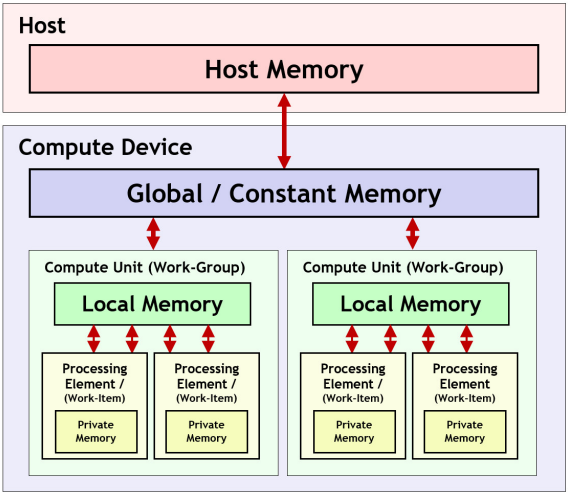

Пример 2

См. `myGEMM/src/kernels.cl`, ядро `myGEMM2`
И пояснения из `https://cnugteren.github.io/tutorial/pages/page4.html`

Работа с изображениями

- OpenCL поддерживает изображения на уровне типов
- Для работы с ними имеются соответствующие API
- Информация о формате и размере изображения передаётся при загрузке в память
- Внутри ядра необходимо использовать сэмплеры — объекты, которые описывают, как извлекаются элементы изображения
  - какая используется координатная система (целочисленные или нормализованные координаты)
  - как обрабатывается ситуация выхода координат за пределы изображения (обнуление или установка «цвета» ближайшего элемента
  - производится ли интерполяция при извлечении значений, расположенных «между» элементами изображения

Пример 3

См. директорию `cpp_gaussian_filter_example`

Продвинутые возможности

- Интеграция OpenCL и OpenGL
- Offline компиляция ядер
- Асинхронность
- Использование нескольких устройств

Полезные ссылки

- Презентация Григорьева С. В.
  - https://github.com/YaccConstructor/articles/blob/master/2025/GPGPU_OpenCL_Intro/SemyonGrigorev_YWS_GPU_OpenCL.pdf
- Khronos OpenCL
  - https://www.khronos.org/opencl/
- Курс по разработке под GPGPU от EuroCC National Competence Center Sweden
  - https://enccs.github.io/gpu-programming/
- Cornell University, Understanding GPU Architecture
  - https://cvw.cac.cornell.edu/gpu-architecture
- Антонюк В. А. OpenCL Открытый язык для параллельных программ, учебное пособие, 2017.
  - https://istina.msu.ru/publications/book/76785028/
- Tutorial: OpenCL SGEMM tuning for Kepler
  - https://cnugteren.github.io/tutorial/pages/page1.html